

SemiAnalysis 创始人 · Dylan Patel

AI 已经在印钞 内存还要涨 2-3 倍

▶ 视频+解读

AI未来课代表

SemiAnalysis的创始人：AI到底赚不赚钱？为什么说内存是这轮最硬的主线？（视频+原文解读）

原创 AI未来课代表 AI未来课代表 2026年07月13日 16:41 上海

课代表

本期是WisdomTree播客《The Next Big Thing》首期，嘉宾Dylan Patel是半导体与AI研究机构SemiAnalysis的创始人。这66分钟，他其实在回答几个躲不开的问题——

1. 天天有人喊AI是泡沫，可Anthropic到底赚没赚到钱？
 2. 为什么说内存是这轮最硬的投资主线，逼得明年iPhone都得涨价？
 3. 都说电力是AI的终极瓶颈，他凭什么说“它也不是瓶颈”？
- 整理成中文七个话题，分享给同样想看懂AI基建这盘棋的你。

📖 阅读说明 | 本文正文是 本期访谈内容；凡涉及外部资料的对照、背景或另一种说法，一律放在这样的 灰色虚线框 里，并标注 **【外部分析·非本次访谈】+ 来源 + 日期**，请勿与 Dylan本期的原话混为一谈。

30秒读懂

01. AI到底赚不赚钱？Dylan的答案是 **「已经在印钞」** ——Anthropic四月、五月已盈利且自由现金流为正，经常性收入破500亿美元ARR、毛利率70%+。

02. 硬币另一面：SemiAnalysis自己一年AI支出从去年11月的不到10万美元，飙到今天的 **1100万美元**（峰值1400万），一家90人公司，AI花费已是薪资的三分之一还多。


03. 省钱的反直觉真相：**用最新最贵的模型，反而最便宜**。同质量下AI成本每年降约60倍，DeepSeek两年内比GPT-4便宜了600倍。

04. **内存超级周期是这轮最硬的主线** ——产能每年只增20-30%，需求却在翻倍，价格已涨约4倍、还要再涨2-3倍。代价：明年iPhone、MacBook必须涨价。

05. CPU从「三年没人提」到「今年满世界喊」，但Dylan泼冷水：**卖方把CPU/GPU比例吹过头了**，大头的钱仍流向AI算力和内存，这只是补涨小周期。

06. 电力才是终极瓶颈——但 **「也不是瓶颈，看你愿意疯到什么程度」**：把卡车发动机改成发电机堆几百台，两年后光伏+储能比燃气还便宜，再极端就是把数据中心发射到太空。

AI 基建的 七个战场



1

贯穿全篇的一把尺子 | Dylan判断供应链任一环节能不能涨、涨多少，反复用同一套框架： 需求传导率 （AI每花1美元，落到这个环节是1分钱还是5分钱） $\times$ 市场结构 （垄断、寡头还是大宗商品） $\times$ 价格弹性 （TSMC只涨5-10%，内存能上下摆2-3倍）。一句话记住这期：**几乎所有东西都在缺货，问题不再是能不能拿到货，而是要等多久。**

01.

从「网上发癫」到90人研究帝国：SemiAnalysis是怎么炼成的

要听懂后面所有判断，得先知道Dylan是谁——一个把技术、供应链、金融、地缘揉在一起看的人，和一家靠5000万美元捐赠硬件天天跑基准测试、连黄仁勋都得在台上回应的研究机构。


一个从十几岁就在论坛「发癫」的人

SemiAnalysis的起点，用Dylan自己的话说就是「在网上发癫」。他十几岁出头就在发关于芯片、手机SOC、屏幕的帖子，还没拥有第一部智能手机就已经痴迷；**12岁**就在管理Android、Apple、Intel、NVIDIA、AMD相关的论坛和Reddit板块。「我一直是个爱发帖的人」——现在他手下90人的公司里，市场部同事求他别再回复网上那些路人，但他就是有那种「一有人批评我就非回不可」的冲动。

他在美国Georgia州农村的一家汽车旅馆里长大，父母开旅馆、后来还开加油站，从小就懂生意、对「东西是怎么造出来的」有种天分。做过两年quant，2020年幻灭辞职——「钱是能赚到，但真没那么光鲜」——然后用真名在自己搭的WordPress上写技术、商业、金融、供应链混在一起的东西。

成名作很能说明他的方法论：Huawei被禁用TSMC时，美国市场都以为赢家是Qualcomm，他第一篇文章却判断真正的大赢家是台湾的 **MediaTek**——因为地缘上，刚被美国封了的中国，更愿意从台湾公司买而不是美国公司。「**这种拐点，我总能在华尔街任何对冲基金之前先喊出来。**」

一路滚下山坡 SemiAnalysis 团队



四年跑160场大会，滚出一支「疯狂人才密度」的队伍

有四年时间他满世界跑，一年参加 **40场大会**，从NeurIPS、ICML这样的顶级AI研究会议，一直跑到只有300人、除了5个人全说日语的半导体化学品原料小会。「一个会去三次，你就懂那套行话、认识那些人了。」把整个产业链上上下下跑遍，哪儿出现拐点，他立刻知道它在供应链和金融层面会往哪走。团队也像雪球一样越滚越大：

时间	团队规模
2023 → 2024	2 → 7人
2024 → 2025初	7 → 20人
2025 → 2026	20 → 60人
今年	90人（一年新增30）

人才密度是他最得意的地方：来自ASML、Applied Materials、LAM Research这些晶圆设备公司，一直到Intel、TSMC、NVIDIA、Microsoft、Amazon，还有在OpenAI做过模型、在Tesla做过FSD、在Cohere干过的人——甚至有个成员在哈萨克斯坦建过一座发电厂。「大概一半人是在这个行业做过工程的，另一半要么是前对冲基金的，要么就是我在Twitter、Discord上发现的、超有热情的聪明人。」

从「内存是最大赢家」到卖数据服务

2022年Substack越做越大后他开始招人，头两个是Discord上认识多年的技术朋友，第三个Myron来自对冲基金。招Myron的方式很「Dylan」：2023年初他发了一篇文章，判断「**内存是AI浪潮里最大的赢家**」——因为AI服务器用的内存比普通服务器少得多（普通服务器的物料成本里约一半是内存，AI服务器里这个比例低得多，部分因为NVIDIA的利润率实在太高），然后在付费板块末尾附了一句「我在招人」。Myron就这么找上门，成了公司第一个对冲基金背景的雇员（前两个都是技术出身）。

他一加入，团队就开始做各种模型，把业务从「写newsletter」转向**卖信息服务、卖报告、卖数据集**——雪球从此滚下山坡。**有意思的是，这个「内存是赢家」的判断后来彻底反转**：NVIDIA下一代芯片的内存用量暴增，内存从「最大赢家」一路变成了本文第4章的「超级周期主角」。

\$50M硬件实验室，和黄仁勋「藏了后手」的名场面


SemiAnalysis有一批工程师专做开源基准测试。OpenAI、Microsoft、Amazon、Google、CoreWeave、Nebius、Crusoe、Oracle等云厂商累计捐了**超过5000万美元**的硬件——8种GPU（H100、H200、Blackwell、AMD各款）外加Google TPU、Amazon Trainium。他们每晚都在最新的CUDA、PyTorch、vLLM、SGLang上跑一遍基准，覆盖「token吐得多快 × 性价比多高」的整条曲线。这套东西叫**InferenceX**。

名场面就出在这里。Blackwell发布时，黄仁勋声称性能提升**25倍**，没人信——Dylan当时觉得顶多15-20倍，还有一堆人喊「也就3倍」。结果InferenceX实测：在DeepSeek V3上，Blackwell在某些区间比Hopper快了整整**30倍**。Dylan拿到结果立刻给黄仁勋发邮件认错：「你2024年说25倍大家都喷你，连我也喷了，但我错了，你其实是留了后手。」

他没想到黄仁勋会把这段搬上GTC舞台。5.5万人看直播、2万人在场馆里，黄仁勋当众点名Dylan，花了整整5分钟讲「Dylan说我藏着掖着，但我没有」——**讲他的时间比讲全场任何人都长**。SemiAnalysis还做了一条印着「Inference King」的WWE冠军腰带，寄给NVIDIA、AMD、SGLang、vLLM这些合作方，黄仁勋直接把腰带举上了PPT。


一个从论坛发帖起家的人，如今成了连全球最大公司CEO都要在台上回应的「基准裁判」。

我错了 你确实藏了后手



1

8种GPU + TPU + Trainium, 每晚跑基准



1

02.

AI到底赚不赚钱？一面在印钞，一面在疯狂烧钱

投资者最大的疑问就是ROI：这些公司到底有没有从AI上赚到钱？Dylan把它拆成硬币的两面——卖AI的人已经在印钞，买AI的人则在经历支出的指数级爆炸。

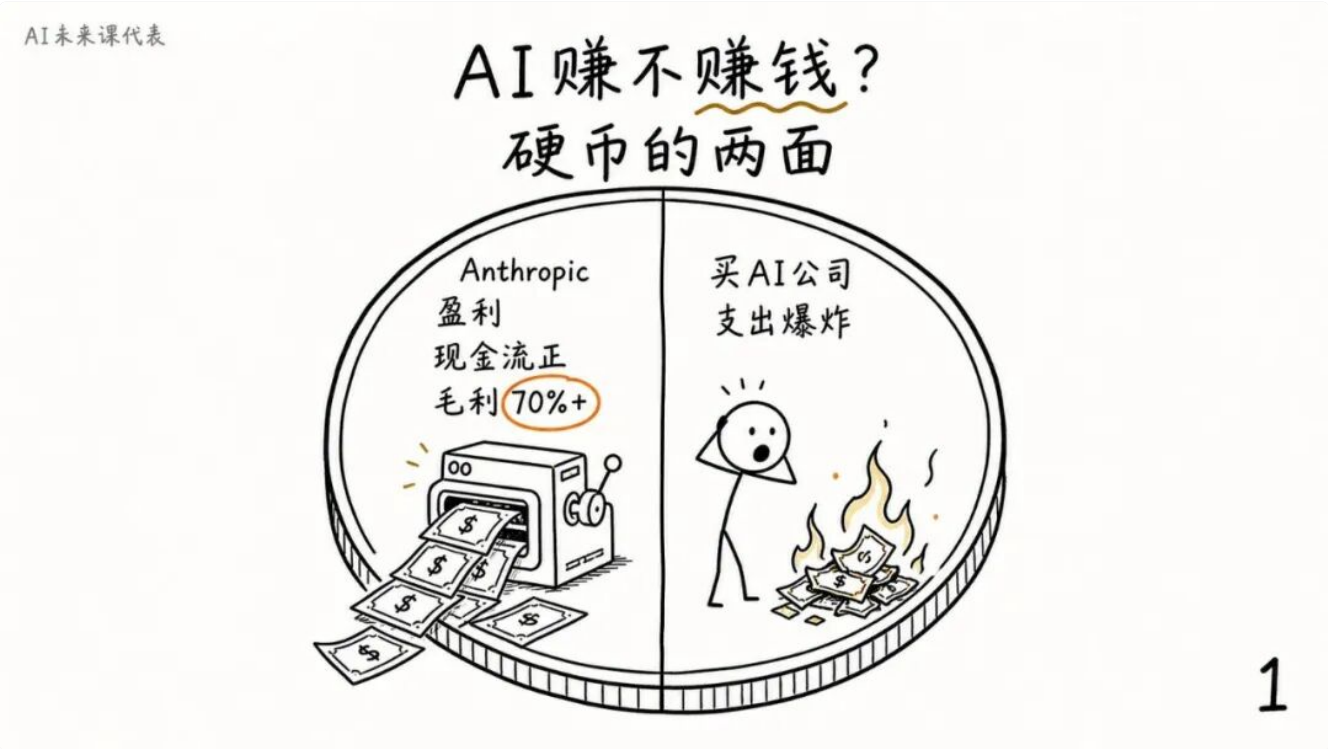
卖AI的一面：Anthropic已经在「印钞」

这是Dylan甩出的第一个、也是最重要的事实：**Anthropic在Q2是盈利的，自由现金流为正**。不是画饼——四月关账时就已经盈利且自由现金流为正，五月同样，六月看起来也一样（还没完全关账）。三个月里至少两个月做到了盈利 + 自由现金流为正。

Anthropic指标	数值
经常性收入 (ARR)	突破500亿美元

毛利率	70%+
盈利 / 自由现金流	Q2已转正（4、5月确认）

其他公司还没到「印钞」的程度，但都在接近：随着Codex采用度上升，OpenAI的收入也开始加速上扬。「这些公司都在变得越来越赚钱。」



买AI的一面：Dylan自曝家底，一年烧掉1100万

他自创了一个词——不是ARR（年度经常性收入），而是 **ARS（Annual Reoccurring Spend，年度经常性支出）**。这条曲线堪称恐怖：

时间	年度AI支出（ARS）
去年11月（Claude Code之前）	< 10万美元
今年1月底	400万美元
今天	约1100万美元（峰值1400万）

去年11月还只是给每个员工开一份200美元的ChatGPT订阅，总共不到10万；Claude Code随Opus 4.5、4.6起飞后，1月底冲到400万，今天约 **1100万美元** ——这还是一家只有90人的公司。**AI花费已经是员工薪资的三分之一还多**，年底可能到「一半对一半」。


📌【外部分析·非本次访谈】 来源：Dylan Patel做客《Invest Like the Best》播客 · 2026-04-23 · 性质：与本期交叉验证

他当时说SemiAnalysis的年化AI支出约 **700万美元**、占薪资25%+；仅两三个月后的本期就更新到约1100万、峰值1400万、占比升到三分之一以上——正好印证他反复强调的「token需求几乎无上限」。

更值得玩味的两个细节：一个年薪30万美元的好开发者，花在AI上的钱正在 **逼近薪资的1:1**；而SemiAnalysis内部花钱最多的，反而是 **不会写代码的人**——他们只管告诉模型自己要什么，然后不断迭代直到拿到结果。

划重点 | 很多公司Q1、Q2就烧穿了全年AI预算，接下来是砍AI还是砍别处？Dylan观察到多数公司在砍其他SaaS、甚至裁员来保AI。**「压制AI使用的公司，会在生产力上被远远甩下。」**

一家90人公司 年度AI账单




1

课代表锐评：「AI是不是泡沫」这个问题，Dylan用一个最难反驳的事实回应——一家头部模型公司已经月度盈利、自由现金流为正、毛利率70%+。泡沫论者该换个问法了：不是「有没有价值」，而是「价值分给谁、每个环节能吃到多少」。

AI账单 ≈ 年薪

年薪30万美元

AI花费



花钱最多的，其实是不写代码的人

1

03.

省钱悖论：想降本，就得用最新、最贵的模型

很多人以为省钱=换便宜模型，Dylan说这是个误解。关键要先把AI工作负载分成两类，它们的降本逻辑正好相反。


第一类：集成进流程——达标即止，等它变便宜

比如「客户发来一份文档，我用模型检查其中某些内容」。这种场景只需要达到某个质量门槛，一旦达标就可以停止追求更强的模型，转而从等更便宜的新模型来降本。这里的降本引擎快得惊人——**同一质量水平，AI成本每年大约降60倍。**

当年大家对DeepSeek那么震惊，就是因为 DeepSeek V3比GPT-4便宜了600倍 ——而它是在GPT-4发布约两年后出现的。按「每年降60倍」算两年该是3600倍，实际落在600倍，反正每年降本幅度就在这条曲线上。

AI未来课代表

两类工作
降本逻辑相反



集成流程
达标停·年降60x



AI助手 / agentic
最新模型

1

第二类：AI助手 / agentic——降本靠最新模型


如果你在做日常智力工作，让模型帮你查、帮你想，成本优化的关键 恰恰不是切到更便宜的模型，而是用最新的模型。因为新模型更聪明、更省token：

同一个任务	消耗
Claude 4.6 Opus	10万token + 来回好几轮 + 我10分钟
Claude 4.8 Opus	2.5万token + 一个来回

生成的token更少、我花的时间更少，总成本反而更低。有意思的是升级后的规律：4.6换到4.7、4.7换到4.8，成本都是先跌一周左右，然后又飘回去——因为大家发现「原来的活干完了，那就再多干点」。所以必须把生产力和成本放在一起衡量。

AI未来课代表

省钱悖论



Claude 4.6 Opus: 10万 token
来回好几轮

Claude 4.8 Opus: 2.5万 token
一轮搞定

更贵的模型 = 更少 token = 更便宜

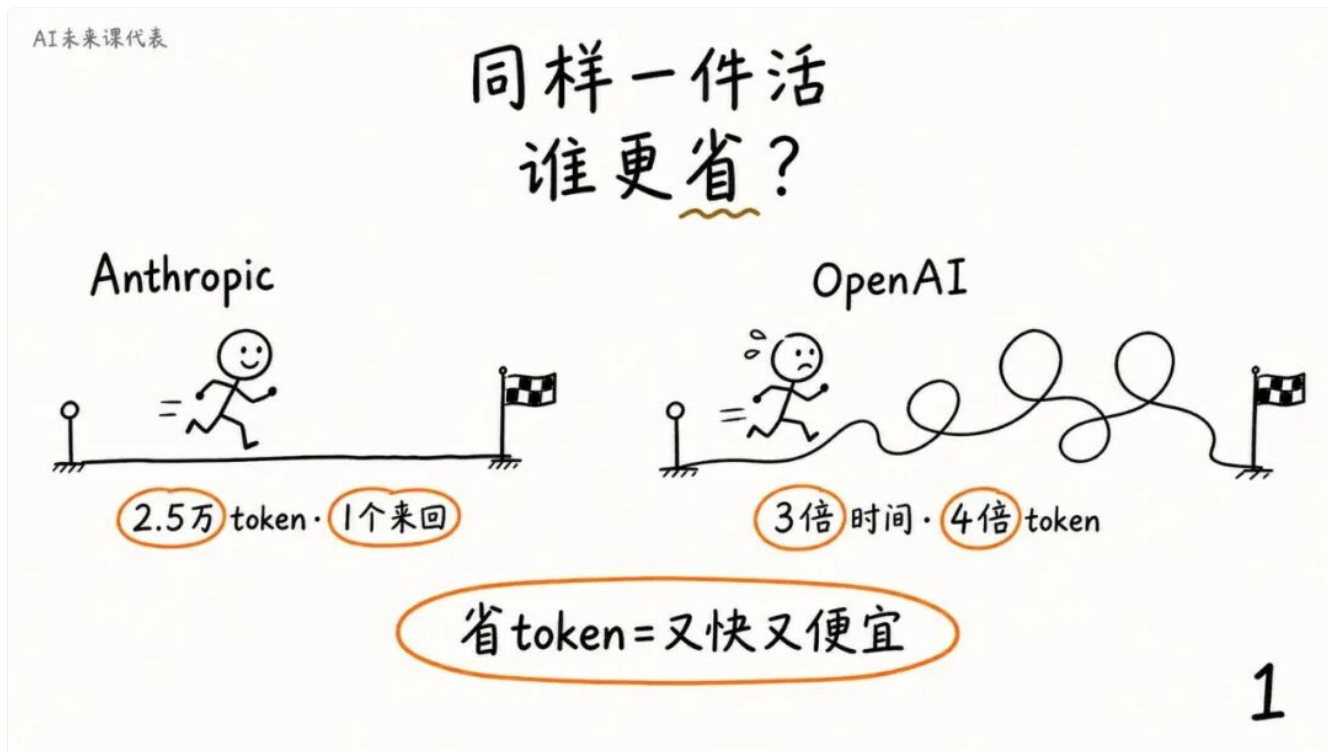
1

为什么SemiAnalysis仍是「majority Anthropic shop」

在AI助手这个场景里，token效率至关重要——这也是 **Anthropic一直压OpenAI一头的原因：它的模型更省token**。OpenAI在顶尖科学、数学、代码的边缘任务上，往往能做Anthropic做不到的事，但要花3倍时间、4倍token，人机反馈循环也更慢，用户感知反而更差。

他举了个绝妙的类比：「你有四个小时做一个任务，是给模型发一次调用让它自己跑四小时好，还是分四次调用来回沟通好？」在人在环路（human in the loop）的反馈循环里，Anthropic因为更省token反而快得多、好得多。所以大多数任务留给Claude Code，只有那些「让它跑一整晚」的任务才交给OpenAI Codex。

在助手场景，最贵的模型往往是最便宜的选择——因为你买的不是token，是「一次做对」。



04.

内存超级周期：这轮最硬的投资主线

内存过去40年一直是典型的大宗商品：18-24个月上行、再18-24个月下行，周而复始。Dylan说这次不一样，而且他从2024年就喊对了这一波。

不是老周期：这次是「总支出翻倍、还要再翻倍」

周期不会消失，我们现在正处在一个「上行猛得离谱」的超级周期里。但关键区别在于：过去上行周期是终端市场涨50%，像内存这种有定价权、弹性大的大宗商品，股票能翻两三倍。这次不是涨50%的事——仅过去几年，总支出已经翻了一倍，而且还要再翻一倍。

内存价格已经涨了大约4倍，接下来除了产能增长之外，价格还要再涨2到3倍；毛利率正朝着一个大宗商品本不该有的水平——85%到90%——狂奔。当然到顶之后又会腰斩回70多甚至更低，所以本质是「疯狂拉升，再回落」的高波动。

供需剪刀差 = 内存超级周期



1

根因：reasoning引爆了KV cache

为什么内存需求会失控？Dylan把技术根因讲透了。做推理（inference）时，每生成一个token，都要把所有权重读进芯片，同时读进上下文（这个上下文缓存就叫KV cache）。从权重这边看，不管上下文是1000还是10万token，内存压力都一样；但从KV cache这边看——**读1000个token和读10万个token，内存需求差得离谱，而计算量几乎不变。**

2024年12月，OpenAI发布o1（第一个reasoning模型），SemiAnalysis当即写下判断：pre-training scaling law正在让位给reasoning scaling law，而reasoning会让KV cache爆炸式增长，**内存将是最大的赢家**。到2026年1月，市场问「内存涨了50%是不是到顶了」，他们又发了一篇：「不不不，你们没搞懂——产能未来三年每年只增20~30%，需求却在翻倍，价格只能一直涨，直到把扛不住的用户挤出去。」

reasoning 把内存需求撑爆了



1


代价：明年iPhone、MacBook必须涨价

价格一直涨，扛不住的用户就被挤出市场——智能手机、笔记本因为成本涨太多，会把内存产能全部让给AI。目前一些中低端中国手机厂商（如小米）出货已经**下降40%**，但高端市场还没受影响。Dylan判断：**明年iPhone、MacBook价格必须上涨**——现在涨100美元市场没啥反应，但内存会一直贵下去直到「AI吃饱」，所以手机涨价不会只涨100，得涨好几百美元，直到达到一个新的平衡点。

这里也体现了框架里的「弹性」差异：TSMC定价没弹性（对客户公道、讲长期，只涨5-10%），而内存是大宗商品，靠现货和合约市场调节，能上下摆2-3倍。同样的AI需求传导到不同环节，价格反应天差地别。

【外部分析·非本次访谈】 来源：Dylan Patel做客《Invest Like the Best》播客 · 2026-04-23 · 性质：背景补充
他当时就点过AI的三大结构性供给瓶颈—— HBM内存、逻辑芯片、EUV光刻，判断会持续2-3年。本期他把「内存」这一条单独拎出来，讲透了背后的量价机制。

内存的短缺不是短期的，是要持续好几年的结构性短缺——这是Dylan押得最重的一注。



05.

CPU卷土重来——但别被卖方带偏

AI爆发的头三年，几乎没人提CPU；今年却满世界都在喊CPU。SemiAnalysis是最早点出这个拐点的，但Dylan也第一个出来泼冷水。


需求为什么起来：RL和agentic都在吃CPU

去年11月，OpenAI和Anthropic开始跟Amazon、Google、Microsoft谈，把它们机队里的CPU买下来或租下来——CPU需求从此一路往上拐。原因有两条：

- 1 | **pre-training** → **强化学习（RL）**：RL要让模型生成推理链或合成数据，再丢进一个环境去校验——跑代码单元测试、模拟网站沙盒、模拟工程系统。这些环境校验需要大量CPU。
- 2 | **chat** → **agentic**：模型不停发tool call（搜索、查数据库、问Python解释器、写代码编译部署），必须跟真实世界打交道，循环里的CPU越来越多。全球GitHub commits同比翻了好几倍，大量代码被生成并部署到CPU上。

划重点 | 关键的转变是：以前是 人 跟模型交互——模型给个回复，我读完、复制粘贴到别处就完事，CPU闲着也无所谓；现在是 模型自己跟互联网世界交互，每一次搜索、查数据库、调Python解释器验证、编译并部署代码，都是CPU在循环里来回跑。而部署出去的又多是网页爬虫、分析引擎、业务流程自动化这类「标准代码」，不挑最快的核、性价比核就够用——这就是CPU需求拐点的真正来源。

CPU 从双雄到五方混战



1

格局：从Intel/AMD双雄到五方混战，人人都能提价

两年前CPU市场还是Intel + AMD的天下，现在变成了五方混战——但奇特的是，Intel、AMD居然都还能提价：

玩家	看点
Amazon (Graviton)	领头羊，造出来是租不是卖，利润率惊人，订单大增
NVIDIA (Vera)	从只卖搭配GPU到单独卖CPU，指引200亿美元营收
ARM	新进入者，股价一路飙涨
Intel / AMD	竞争中竟仍能提价，需求大涨


要快核还是多核？同样是agentic，CPU需求分两种

先记一个CPU架构的取舍：把核做大一倍（核数减半），单核性能只提升约50%、而非翻倍。所以NVIDIA Vera不到100核、但每核更快，AMD旗舰256核、但单核弱。到底该选哪种，取决于工作负载——而agentic其实分成两种截然不同的情况。

第一种：算力会卡住等CPU。模型跑完，把结果交给CPU处理、自己在旁边干等——比如等一段代码在沙盒里跑完才能继续。这时几万美元的AI算力被卡住空转，代价极高，所以你宁愿要「核数少一半、但单核快50%」的CPU，让这个任务尽快跑完。**这正是NVIDIA Vera的定位。**

第二种：算力不会浪费。我拿到回复去实施时，模型的算力立刻转去服务成千上万的其他用户——算力没闲着。这时CPU慢一点无所谓，只要核多、够便宜就行，Amazon Graviton、AMD正合适。还有「部署AI生成的代码」这一路：全球GitHub commits同比翻了好几倍（不是涨10%、50%，是翻几倍），海量代码被生成、部署，跑的多是网页爬虫、分析引擎、业务自动化这类标准代码，用性价比核就够。**所以这是一条连续谱：NVIDIA站「最快单核」一端，AMD、Amazon、ARM站「多核便宜」一端。**

要核多，还是要核快？



AMD: 256核 | 单核慢

NVIDIA Vera: <100核 | 单核快

核翻倍，单核快50%

1

泼冷水：卖方把CPU/GPU比例吹过头了

自从SemiAnalysis点出这个拐点，ARM、Intel、NVIDIA、AMD的股票都暴涨。但Dylan说，那些「根本不懂技术的卖方分析师开始瞎编」——把CPU/GPU比例吹到「CPU比AI算力还占大头」的程度，**这是错的**。算笔账就明白：一颗满配Blackwell 5万多美元，按1:1配CPU也就5000美元——要卖3000亿到5000亿美元的Blackwell，只能带出300亿到500亿美元的CPU。

大头的钱仍然流向AI算力和内存。本轮CPU的真相是「补涨 + 比例修正」的小周期：过去三年出货了上千万颗GPU和AI ASIC，基本都没配够CPU，现在是一次巨大的补涨加上比例本身上移；等把积压的缺口补齐，就只剩增量、进入稳态。**不是CPU需求会永远超过AI芯片。**

CPU确实被低估过、现在定价更合理了——但把它当成下一个GPU来炒，就是被卖方带偏了。

课代表锐评：这一章是整期最有「卖方vs买方研究」分野的地方——同一个CPU热点，卖方讲成长故事，Dylan用一颗芯片的美元拆分把叙事拉回地面。判断一个主题时，先问「每1美元AI支出到底落到它头上多少」，比听增速百分比靠谱得多。

CPU的分量， 被卖方高估了



1

06.

光vs铜：市场对CPO太亢奋了

网络是这轮增速最快的环节，但Dylan在最热门的CPO（共封装光学）上给出了一个明确的反共识判断。

网络价值量在飙升


随着模型越来越大、集群越来越大，网络的增速比任何环节都快。在AI芯片相关支出里，网络占比正从不到10%涨到10%以上；到了CPO时代能到20%~30%。电信光（像Sienna股价一直飙）、data com（芯片到芯片，铜和光并存）都在猛涨。

反共识：CPO要到2029才真正放量

CPO现在大家都认，但Dylan说「市场有点过于亢奋了」。他的时间表和主流不一样：

时间	CPO进度（Dylan判断）
2027	不可能落地
2028年末	才开始起步
2029	才是大规模放量的关键年

原因是制造：产能、良率、芯片设计都没就绪，极难量产。所以大家能用铜就尽量用铜——Ruben全铜、Feynman（Ruben、Ruben Ultra之后的下一代GPU）仍是铜，而Ruben现在都还没开始出货。交换机上的CPO会比GPU/ASIC更早，但就算不上CPO，集群越大每颗GPU需要的光模块和有源电缆也越多。




中期押注：看多铜 + 非CPO光模块，看空CPO

SemiAnalysis周一刚给机构订户发了一份note：技术上CPO终会到来、铜最终会被取代，但 中期维度上，他们非常看多铜和非CPO光模块、反而看空CPO——因为看到下游一些芯片延期（Feynman没全面上CPO）。做背板连接器和电缆的 Amphenol 这类铜相关公司，未来几年表现会比之前预期好很多（此前市场以为CPO会更早放量，如今被往后推了）。


为什么铜这么顽固？归根到底，集成光器件比走电信号贵太多——只有当你不得不走电、又走不了那么远时，才需要加中继器或上光。而铜产业本身还在大量创新，反过来又把CPO往后推。所以「能用铜就用铜」不是保守，是一笔实打实的成本账。SemiAnalysis跟WisdomTree一起做的，正是给「CPO光模块 / 非CPO光模块 / 传统光收发 / 铜连接」各自该占多少权重做出判断。

光模块是「你今天闭上眼、五年后睁开会大得多」的赢家，但中间的局部错位，正是研究能赚钱的地方。

光 vs 铜： 未来几年铜先赢



AI机柜里 铜的用量在暴涨



07.

电力：终极瓶颈，也「不是瓶颈」


聊完模型、GPU、CPU、内存、网络，绕不开每个数据中心里那头「房间里的大象」——电从哪来。而SemiAnalysis最大的研究板块，恰恰就是它。

数据中心增长曲线，和三段式拆解

今年部署 **20吉瓦 (GW)** 数据中心，明年30GW (+50%)，后年50GW。三大制约按难度排：**能源 > 政治 > 施工许可**。而能源又能拆成三段，各有各的机会与难处：

- 1 | **发电**：电网发电量在增，同时出现「专门为数据中心发电」的大趋势。
- 2 | **输电**：**最难看好**——监管政治阻力大，本地公用事业垄断，建一条线成本要摊给所有用户。
- 3 | **转换**：把电网的电转换成芯片能用的形态，一整条精彩的供应链（下文详述）。

电从哪来， 怎么送进芯片



1


表后自建电站大爆发：把卡车发动机改成发电机

最有意思的是「表后自建电站」（behind the meter）。Dylan预计再过几年，**数据中心新增用电的一半将在场内自发，而不是从电网输入**。主力是天然气（GE Vernova、Mitsubishi、Siemens的双联合循环机组），但更疯的是一人们把火车、轮船、卡车的发动机拿来改烧天然气、反向驱动电动机发电。

美国一年能造上百万台往复式发动机，把柴油改成烧气很容易，就算继续烧柴油也行。**10GW**以上的数据中心会用这种方式来建：一个站堆上几百台，从汽修店雇一批机修工整天维护，中间配电池缓冲负载波动。审批仍有博弈（空气许可、天然气管道），Oracle的数据中心就遇到过。「很多人说这也太恶心、太不可靠了，但确实有人在这么干，而且它真能跑。」

再往远看是一条完整的谱系：约两年后**光伏 + 储能**会比燃气还便宜（得益于中国的制造能力和补贴），但要看你要几个9的可靠性——够撑一夜便宜，够撑连续三天下雨就贵了；最极端的是**太空数据中心**，连电池都不用，装块太阳能板扔上去就行。

愿意疯到什么程度 就有多少电



1

SemiAnalysis最大的板块，竟不是半导体


你可能以为一家叫SemiAnalysis的公司，最大的数据集是半导体——其实是**数据中心 + 能源 + 工业**（内部戏称DEI team，Jeremy带队）。他们追踪每一个数据中心、每一座发电厂，能算出哪个项目延期、哪家公司这个季度有多少数据中心上线——「这是行业里没人能做到的事」。Google想知道Meta能部署多少、Meta想知道OpenAI，

所有投资人都在盯。

而且这是个 **极度分散** 的市场：内存就3家、设备就几家，但数据中心/能源有几百家公司做着各种零碎部件，几十家在建数据中心，遍布台湾、日本、韩国——「散户根本不容易接触到」。转换环节同样精彩：IGBT、碳化硅、GaN氮化镓MOSFET，12V→54V→800V直流转换，固态变压器，UPS/蓄电池/超级电容平滑「脏电→干净电」。（NVIDIA把Kyber往后推、Ruben Ultra Kyber不再上800V，供应链节奏也随之后移。）

越往供应链深处走，越是一堆不起眼、却真会缺货的小环节。Dylan举例：有好几个月他们一直在聊 **PCB钻头**（给电路板打孔用的钻头）、PCB上贴的 **铜箔**，还有 **MLCC片式电容**——这些环节同样会供需错位、股价大涨，但相关公司散落在台湾、日本、韩国上市，**散户根本接触不到**。「我们平时聊得多的都是内存、CPU、数据中心这些大环节，但真正深入供应链，会发现局部的痛点非常小、又非常多。」

「数据中心会继续是某种瓶颈，但也不会真成瓶颈——取决于你愿意疯到什么程度。」



08.

课代表总结：3个不该被噪音淹没的判断

数字和公司名很多，但真正值得记下来的，是它们背后的3个判断。

判断一·ROI之争已经结束，战场转向「谁分到钱」

当一家头部模型公司已经月度盈利、自由现金流为正、毛利率70%+，同时连一家90人研究机构自己都愿意一年掏1100万买token，**「AI有没有价值」这个问题就已经被事实回答了**。接下来真正的分歧，是需求会怎样传导——从模型一层层流向内存、CPU、光、电，每个环节能吃到多少。

泡沫论者该换个问法了。

判断二·用一把尺子量所有环节，别追单个热点

内存为什么最硬、CPU为什么被高估、CPO为什么被提前炒作——答案都出自同一把尺子：**需求传导率 × 市场结构 × 价格弹性**。内存三者全占（需求翻倍、寡头、大宗商品弹性），所以是超级周期；CPU传导率有限（每10万美元GPU只带5000美元CPU），所以只是补涨小周期。**同样喊「缺货」，能不能涨、涨多久，得用这把尺子量，而不是听增速百分比**。

卖方讲故事，买方研究拆美元。


判断三·瓶颈都是暂时的，就看愿意多「疯」

这期最反直觉的一句话是「电力是瓶颈，也不是瓶颈」。当解法可以疯到「把卡车发动机改成发电机堆几百台」「把数据中心发射到太空」，真正的约束就不再是物理，而是「你愿意为算力付出多难看的代价」。这也解释了为什么这波基建的天花板，比大多数人想的高得多。

供给的想象力，就是需求的天花板。

AI 未来课代表

别被噪音淹没 三条判断



1

最终判断

Dylan Patel这66分钟，本质是把「AI是不是泡沫」这个宏大问题，翻译成了一张可操作的供应链地图：AI已经在印钞，需求几乎无上限地传导到每一个正在缺货的环节，但每个环节能吃到多少、涨多久，取决于它的市场结构和弹性。**内存是这轮最硬的超级周期主线，CPU是被卖方高估的补涨小周期，CPO被市场提前亢奋、铜还有很长的路，而电力这个终极瓶颈「也不是瓶颈」。**对投资者而言，价值不在于知道「AI很大」，而在于拿着这把「需求传导 × 市场结构 × 弹性」的尺子，去量每一个被喊成「下一个短缺」的名字。

本文内容翻译整理自WisdomTree播客《The Next Big Thing》2026-07-09期原文，仅供学习交流，可能存在翻译偏差或遗漏。如有疑问欢迎对照英文原版收看，也欢迎业内专家在评论区指正与补充。内容仅供参考，不构成任何投资建议。

点击下方关注公众号，设个星标

才能及时接收最新推送