



SemiAnalysis迪伦·帕特尔：AI本质是能源与内存的竞赛，CPU正进入大规模补课期

瓜哥 瓜哥AI新知 2026年07月14日 22:21 浙江

🔔 关注公众号后设🔔 标，掌握第一手AI新动态

本文内容整理自 [SemiAnalysis Founder Dylan Patel](#) 在 [WisdomTree in Europe](#)频道的专访，公开发表于2026年07月09日。原始内容参考：
<https://www.youtube.com/watch?v=IHnxU9f-rwc>

内容提要：迪伦·帕特尔在WisdomTree专访：AI竞争的终局是能源与内存，CPU正迎来被低估的“大规模补课期”

- **AI基础设施的“冰山效应”**：真正的AI竞争已从单纯的GPU芯片，转移到了整个工业体系的协同。供应链中充斥着如PCB钻头、铜箔等不起眼却极易产生供需错位的小零件，这些环节的短缺往往被市场所忽略。
- **推理模型的成本曲线**：AI模型的性能比正以每年约60倍的速度飙升。对于已形成标准化工作流的企业而言，策略应转向成本控制（使用固定质量的低成本模型）；而对于复杂的推理任务，采用最顶级的模型反而因极高的Token效率和更少的中间步骤，在总成本上更具竞争优势。
- **CPU需求的“迟到补丁”**：AI并非不再需要CPU，而是存在严重的配套积压。随着训练向强化学习及AI智能体（Agent）工作流演进，CPU的需求正处于大规模的“追赶式”爆发阶段。一旦历史积压被消化，市场将回归平稳的增量增长。
- **数据中心能源的“野路子”**：能源供应已成为AI规模化的核心瓶颈。为突破电网输电限制，行业正通过“电表后”（Behind-the-meter）现场发电另辟蹊径，例如将柴油卡车发动机改装为天然气发动机，或利用工业级往复发动机就地供电。这折射出AI基建在极端需求下的生存法则与灵活性。
- **内存的超级周期**：随着AI推理模式从“对话”转向“Agent长视角推理”，KV Cache对内存的需求呈爆炸式增长。然而，内存产能年均增速仅为20%-30%，远无法匹配翻倍的需求。这不仅将导致未来数年内价格持续走高，还将迫使手机、笔记本等消费电子市场面临大幅涨价的压力。
- **共封装光学（CPO）的预期偏差**：市场对CPO（共封装光学）的落地预期过于乐观。受制于良率与制造复杂性，在CPO真正实现大规模商用之前，铜缆技术在未来几年内依然具备极强的生命力，且因其成本可控，短期内的市场表现极可能超出预期。

SemiAnalysis Founder Dylan Patel简介

迪伦·帕特尔（Dylan Patel）是科技咨询公司SemiAnalysis的创始人兼首席分析师，在半导体和人工智能行业享有极高的影响力。他毕业于加州大学伯克利分校，曾担任硬件工程师。凭借对芯片供应链、先进封装技术及AI基础设施深度的技术洞察，他迅速成长为全球科技投资界与产业界的核心智囊。

迪伦·帕特尔及其团队以发布极具前瞻性的行业分析报告而闻名，内容涵盖从英伟达（NVIDIA）的GPU架构演进、台积电（TSMC）的晶圆制造工艺，再到OpenAI等大模型厂商的底层算力需求。他的观点常被《华尔街日报》、《金融时报》等主流媒体引用，被视为解构现代科技硬件生态系统最精准的观察者之一，其洞察往往能直接影响半导体行业的市场走向与估值逻辑。

内容简介

人工智能正在重塑全球各行各业，而在每一个AI模型的背后，都隐藏着一个日益复杂的底层基础设施堆栈，为其提供源源不断的动力。

在本期《The Next Big Thing》播客中，我们与SemiAnalysis创始人迪伦·帕特尔（Dylan Patel）展开深度对话，探讨支撑这场AI革命的底层技术。从GPU、内存、网络，到数据中心、能源与电力设施，我们将全方位解析AI技术栈的每一个层级是如何加速演进，以满足史无前例的算力需求的。

我们探讨了AI智能体（Agent）的崛起，为什么在GPU之外，CPU的地位也变得愈发重要；分析了内存与网络所扮演的全新角色，以及为什么电力供应正成为制约AI发展的最大瓶颈之一。此外，本期节目还将揭示整个半导体与基础设施生态系统中的企业，是如何全力应对这场数十年来规模最大的工业基建浪潮的。

访谈全文

主持人：好的。大家好，欢迎回到《Next Big Thing》播客的新一期节目。今天和我一起参与节目的有我的同事 Blake Hyman，以及我们的新合伙人——研究机构 SemiAnalysis 的创始人 Dylan Patel。

今天非常令人激动，我们将与 Dylan 一起探讨 AI 基础设施领域的现状。大家可能在许多不同的播客中听到过 Dylan 的分享，我一直都在关注他的内容，包括 SemiAnalysis 网站上的简报(Newsletter)。最近，我看到了一篇关于太空数据中心的文章：如果有对此感兴趣的朋友，这篇非常详尽的文章绝对不容错过。

Dylan，我很想听听 SemiAnalysis 最初的构想是怎么来的。我知道如今在 Substack 社区里，人们经常讨论这家公司的营收和它所取得的巨大成功。然而，我觉得大家往往只看到了眼前的光鲜，却忽略了来时的路，以及背后倾注的无数心血。

迪伦·帕特尔：我认为 SemiAnalysis 的起源其实源于“shitposting”（在网上随意发帖吐槽）。回看我最早关于半导体的帖子，那还是我十一二岁的时候。我当时在网上发各种关于芯片、智能手机、手机屏幕、手机系统级芯片(SoC)以及其他硬件的内容。甚至在我自己拥有智能手机之前，我就已经对这些东西痴迷了。游戏硬件也是如此——无论是 PC 硬件还是主机硬件。我一直在各大论坛上发这些东西。到了 12 岁时，我已经在 Reddit 上担任了许多与 Android、Apple、Google、Intel、Nvidia、AMD 以及各类硬件主题相关论坛的版主。这就是一切的起点；我天生就是个发帖狂人，习惯于发表观点、回复网友并与评论区互动。



我们的团队现在拥有 90 人的规模，一件很有意思的事是，我们营销部门的人经常劝我：“Dylan，别再理网上那些无脑喷子了，这会拉低我们的档次。”但我就是有那种按捺不住的冲动，想要去怼回任何在网上批评我的人。也许这并不好，但整个青少年时期，我都是在管理这些论坛中度过的。我十七八岁一赚到钱就开始投资，后来做了两年的量化分析师(Quant)，接着就创立了自己的公司。但在整个过程中，我始终没有停止过发帖。我写过匿名博客，也发过匿名帖子。

2020 年，我厌倦了当时的工作。作为量化分析师的幻灭感很强——它并没有看起来那么光鲜亮丽。虽然确实能赚到钱，但远没有外界吹捧的那么神仙。我算是“精神离职(quiet quit)”了，并开始创办自己的公司。当时我并不确定未来会怎样，只是建了一个 WordPress 网站，开始用真名发帖。内容涵盖了技术、商业、金融和供应链——这些都是我最感兴趣的领域。我从小在做小生意的家庭中长大；父母在佐治亚州的乡下经营一家汽车旅馆，我们就住在里面。后来我们还开了加油站，所以我对做生意门儿清。我耳濡目染，也一直很喜欢商业。从投资和万物制造的角度来看，供应链一直是个非常有趣的话题；我觉得洞察这些始终是我的天赋所在。

技术和金融的结合也让我非常兴奋，所以我把它们揉在了一起。我最初的帖子写的是美国禁止华为获取台积电(TSMC)代工服务这类事件。其实我的第一篇文章写的是：联发科(MediaTek)才是最大的赢家。因为当时华为在中国智能手机芯片乃至整体智能手机市场的份额都高居第一。显而易见，由于无法再使用台积电的服务，市场格局即将生变。当时美国市场普遍认为高通(Qualcomm)会胜出，但我认为台湾企业联发科会抢下更多的市场份额。事实证明，从地缘政治的角度来看，既然美国刚刚制裁了华为，中国企业自然更倾向于从台湾供应商而非美国供应商那里采购。最终两家公司都从中受益，但联发科吃到的红利要大得多。

正是技术、供应链、金融和地缘政治的结合，让这一切交织在了一起。随后的几年里，我把 WordPress 搬到了 Substack 上，开启了付费订阅，并开始撰写横跨整个半导体和 AI 供应链的文章。我一直密切关注 AI，做量化分析师时甚至还做过一点 AI 方面的工作。此外，出于纯粹的热爱，我也一直在追踪半导体行业。

业务就这样雪球般越滚越大。过去的四年里，我满世界跑，参加了全球各地的相关会议。我一年要跑 40 场会。我居无定所，像朝圣一样奔赴我能参加的每一场会议，无论是 NeurIPS、ICML 还是 ICLR 这样的 AI 顶级会议。这些主要是 AI 研究人员和部分企业展示前沿成果的学术平台。我的研究打通了整个生态的上下游，一路向下游延伸，甚至会去参加那些探讨半导体供应链上游化学原料的冷门会议。我纵贯了整个技术栈——服务器、网络、晶圆制造(Fabrication)、人工智能——一年参加 40 场会议。有些会议极其小众，只有 300 人参加，全场除了 5 个人之外全都讲日语；而有些大会则有 1 万到 2 万人。我借此跨越并看清了整个生态系统。

只要一个会议你连续参加三次，你就能真正掌握他们的内行话并结识圈内人。通过建立人脉，你可以直接向他们提问，我也由此构建了自己庞大的认知生态系统。我紧盯着每一场活动中透露出的行业拐点。我对技术有着强烈的好奇心，一旦发现亮点——无论是技术突破还是供应链变动——我就能预判它在供应链或金融市场上将引发怎样的蝴蝶效应。我把这些融合成深度分析。有时候报告纯粹聚焦技术，金融圈的人根本不感冒；但有时候，他们会恍然大悟：“哇，原来这就是瓶颈所在，”或者“这就是正在发生的行业拐点，”又或者“这家公司将凭借下一代技术疯狂收割市场份额。”我会比华尔街的任何分析师、比任何对冲基金、比所有人都要更早地预判这一切。这就是一切的开端。

随着 Substack 业务在 2022 年的爆发，我开始招兵买马。前两名员工是我在 Discord 上认识多年的老友。第三名员工是 Myron，他曾在对冲基金工作，当时正准备搬到日本和妻子团聚，这让他成了职场上的“自由人”。时间回到 2023 年初，当时我写了一篇文章，论述为什么内存(Memory)是 AI 浪潮中最大的输家。原因在于，AI 服务器使用的内存量与普通服务器相比要少得多。在普通服务器中，大约一半的物料清单(BOM)成本是内存，而在 AI 服务器中，这个比例要低得多。当然，后来 NVIDIA 的下一代芯片大幅增加了内存容量，这是后话。Myron 就是在那篇文章发布后联系我的；他是我们第一位拥有对冲基金背景的员工，而另外两位都是技术出身。

Myron 一加入公司，我们就开始构建财务和行业模型。我们将业务从单纯的简报转变为一家信息服务公司，开始销售深度报告和数据集。随着转型的推进，势头就像滚雪球一样势不可挡。从 2023 年到 2024 年，我的员工从 2 人增加到 7 人。接着从 2024 年底到 2025 年初，从 7 人增加到了 20 人，而从 2025 年到 2026 年，又从 20 人激增到了 60 人。到了今年，我们的规模达到了 90 人；单是今年我们就新增了 30 人。这完全是一种滚雪球效应。

我们不断拓展研究领域。我一直对万事万物都充满好奇，但现在，我有能力把真正的行业专家招致麾下。我认为 SemiAnalysis 最令人兴奋的一点在于：放眼望去，我找不到第二家能拥有我们这种专业深度和极高人才密度的机构。我的团队里，既有曾在 ASML、应用材料(Applied Materials)和泛林集团(LAM Research)——这些制造晶圆的设备巨头——工作过的人，也有曾在 Intel、台积电(TSMC)、NVIDIA、Microsoft、Amazon 等公司深耕过的业内资深人士。

我们有人曾在 OpenAI 参与过模型研发；有人曾在 Tesla 负责全自动驾驶(FSD)；有人曾在 Cohere 工作。我们在模型层有顶尖的专业人员。在另一个垂直领域，我们有数据中心领域的资深专家。我们公司里甚至有个个人曾在哈萨克斯坦建过一座发电厂。我们就这样聚集了极其可怕的人才密度，这简直太棒了。

公司有一半的员工是拥有深厚跨行业背景的实战工程师；另一半则由前对冲基金专业人士，或者纯粹是我从互联网上发掘的、对这行充满狂热的“民间高手”组成。我在 Twitter 或 Discord 上发现了他们，我觉得：“你是个聪明人，来给我干吧。”事实证明这套方法非常奏效。这就是我们团队如今的班底。

如今，SemiAnalysis 拥有多条不同的业务线：数据服务、咨询和信息服务自然不在话下。我们保留了简报业务，在做大量的媒体工作，最近还要举办一场盛大的行业会议，同时还在探索各种不同的新事物。这真是一段极其狂飙突进的精彩旅程。

主持人：说到这段历程，Dylan，有件事让我印象深刻。WisdomTree 和 SemiAnalysis 在过去几个月里一直并肩合作。三月份，NVIDIA GTC 大会如期举行。当时我坐在北卡罗来纳州夏洛特的家中观看直播，大概还有 55,000 人也在同时在线观看。突然之间——

迪伦·帕特尔：现场的体育馆里也有两万人，足足两万人。

主持人：他直接提到了你。你曾说故意隐藏实力 (Sandbagging)，对某些数据有所保留，而你的图表直接被展示在了舞台的大屏幕上。说实话，那一刻我替你感到无比自豪，看着全球市值最大公司的 CEO 在台上直接引用你的研究，并回应你对他的数据提出的批评。我猜你当时应该就在现场吧，很想听听你当时的感受。

迪伦·帕特尔：那一刻感觉非常超现实。SemiAnalysis 的核心工作之一，就是带领一批工程师，对市面上所有的 AI 模型及其底层硬件进行开源基准测试 (Benchmarking)。这是一项非常了不起的工作。除了我们内部的工程师，我们与整个行业也有着极其深度的合作。

我们收到了来自 OpenAI、微软、亚马逊、Google、CoreWeave、Nebius、Crusoe、Oracle 以及所有你能想到的主流云厂商提供的、总价值超过 5000 万美元的硬件捐赠。我们拥有八种不同类型的 GPU，包括 H100、H200、Blackwell 和 AMD 的各类 GPU，此外还有 Google 的 TPU 和亚马逊的 Trainium。我们每天都会基于最新的软件运行基准测试，这是必不可少的，因为每天晚上都可能会有新的 CUDA 版本、PyTorch 版本、驱动更新、推理引擎、视觉语言模型 (VLM) 或 SGLang 版本发布。在自动化的基准测试套件中，我们每晚都会在整个性能曲线上运行这些测试，以在词元 (Token) 生成速度与成本效益之间找到最佳平衡。

当黄仁勋 (Jensen) 最初发布 Blackwell 时，他宣称性能将有 25 倍的提升。当时没人相信他——毕竟那是黄仁勋，大家都觉得他在做营销。即便乐观如我们，基于内部性能模拟器的预测，也只敢给出 15 到 20 倍的提升预期。然而，随着我们开发出推理基准测试工具 InferenceX，我们惊讶地发现：在运行 DeepSeek V3 时，Blackwell 在某些性能区间上的速度，实际上比 Hopper 快了整整 30 倍。

拿到结果后，我立刻给黄仁勋发了邮件，同时将数据自动发布到了我们的开源 GitHub 上。这是双方协作的成果，NVIDIA 的团队也提供了协助，并且清楚这些数据。我在邮件中对他说道：“嘿，Jensen，当初你发布 Blackwell 时说性能提升 25 倍，所有人都在嘲笑你——甚至包括我。我以为顶多 15 到 20 倍，很多人甚至说只有 3 倍。我错了，你其实是在隐藏实力 (Sandbagging) ——实际提升是 30 倍。”当时我并不知道他会作何反应，不过后来我从 Meta 的一位联系人那里听说，黄仁勋一直在会议上使用我们的数据，来证明他不仅没有夸大数据，反而是极度保守的。

最后，我们为贡献者定制了一条“推理之王 (Inference King)”金腰带——它看起来就像 WWE 冠军腰带一样。我们将它寄给了所有的合作伙伴，包括 NVIDIA、AMD，以及 SGLang 和视觉语言模型 (VLM) 的开发者，以致敬他们为这项开源事业捐赠的价值数百万美元的硬件和无数的工程时间。当我在屏幕前，看到黄仁勋在台上花了足足五分钟时间，高高举起我们的金腰带，并用我们的图表来讲述我们当初如何质疑他的断言，最终却又被他无可辩驳的顶级性能所折服时，那一刻，真的太超现实了。

他在整场演讲中谈论我们的时间，比提及任何其他的时间都要长。唯一一个被他提及同样多的大概就是 Claude 了，如你所见，它正以摧枯拉朽之势席卷全球。那确实是一个不可思议的辉煌时刻。

主持人 Blake Hyman：Dylan，你刚才提到的几点中，关于开源的部分非常有趣。现在让我们把话题转向近期的行业动态和市场现状。近来，围绕开源模型与闭源模型在推理效率 (Inference Efficiency) 上的实际差异，业界一直争论不休。

与此同时，许多投资者依然对所有这些 AI 投入的投资回报率 (ROI) 抱有深深的疑虑。就在过去一两周，彭博社的一位经济学家还指出，许多企业的 AI 转型项目可能正面临失败。

我知道你曾强调过你们公司内部在多大程度上拥抱了 AI，并且不遗余力地为员工提供海量的词元 (Token) 使用额度。你刚才也提到你们正在招聘。我很好奇，你是如何看待当下的终端需求的？正是这种需求，正驱动着我们当下所见的大规模算力基建。尽管供应链依然充满瓶颈，但这种需求——至少在近几天市场出现回调之前——一直在推动相关概念股的狂飙。

迪伦·帕特尔：关于这个问题，我想谈几点。当我们审视核心问题——也就是 AI 的投资回报率 (ROI)，以及企业是否真正从 AI 中赚到钱时——这自然会引申出一个更宏大的辩论：这种爆炸式增长可持续吗？使用 AI 的人，真的从中获得了实质性的价值吗？在我看来，我们可以从几个维度来剖析这一现状。

首先也是最重要的一点：Anthropic 已经实现了盈利，且自由现金流转正。他们在四月结账时，同时实现了盈利和正向自由现金流；五月维持了同样的战绩，六月看来也将延续这一势头。即使季度末账目尚未彻底封账，但他们在三个月中实现了两个月正现金流。他们的年度经常性收入 (ARR) 已飙升突破 500 亿美元，并且毛利率远超 70%，业绩表现堪称惊艳。

尽管 Anthropic 显然正在“印钞”，但他们并非孤例。还有许多公司虽然尚未跨过这道门槛，但也正在取得实质性的突破。例如，随着 Codex 等工具普及率的提升，OpenAI 的营收也迎来了爆发式的增长拐点。这些头部公司都在以肉眼可见的速度变得越来越赚钱。

然而，这仅仅是硬币的一面。硬币的另一面，正如你刚才暗示的，是那些正在为 AI 疯狂买单的企业视角。在 SemiAnalysis，我们一直在追踪一个我称之为“ARS”——年度经常性支出 (Annual Recurring Spend) 的指标。去年 11 月，在 Claude Code 真正开始爆发之前，我们的 ARS 还不到 10 万美元。那时候，我们只是给每位员工配备了每月 200 美元的 ChatGPT 订阅服务。即便如此，我们当时在业界也算得上是站在了技术应用的最前沿，能够按需调用各类模型。

但随后，随着 Claude Code 的发布及其后续更新，Claude Code 迎来了真正的爆发拐点。到今年 1 月底，我们的 ARS 直接飙升到了 400 万美元。

这一切，都是因为员工们都在疯狂使用 Claude Code。而到了今天，这个数字已经达到了约 1100 万美元。如果你把我们现在的周支出乘以 52 周，年化支出就是 1100 万美元，峰值时甚至曾达到过 1400 万美元。所以，它会根据大家正在推进的项目出现剧烈波动，但目前的平均年化支出基本稳定在 1100 万美元左右。对于一家只有 90 人的公司来说，这简直太疯狂了。**坦白讲，我们现在已经把超过三分之一的预算砸在了 AI 上，而且到今年年底，这个比例极有可能会飙升至一半——**这取决于像 Mythos 这样的模型还能进化到什么程度。这是一笔极其庞大的开支。

那么问题来了，投资回报率 (ROI) 究竟如何？**我认为我们获得了超乎想象的巨大回报。**正是因为有了 AI，我们得以构建出更加卓越的产品，拿下更多的订单，并成倍放大

了全公司每一个人的生产力。然而，不可否认，许多企业目前正在审视这一成本：假设你有一位年薪 30 万美元的顶尖开发者——实际上很多人的薪水远超这个数——他们消耗在 AI 算力上的支出，正逐渐逼近与他们薪水 1:1 的惊人比例。而对于非开发人员，AI 支出则因人而异；在 SemiAnalysis，我们内部最“烧钱”的 AI 算力消耗大户，反而是那些完全不懂编程的人。他们只需直接用自然语言告诉模型自己的需求，不断迭代，就能直接拿到最终的交付成果。

正因如此，我们正目睹着企业人均 AI 支出的直线飙升。许多公司现在很自然地会陷入焦虑：“我们在第一、第二季度就把全年的 AI 预算烧光了，接下来该怎么办？”摆在面前的难题是：究竟是该削减 AI 支出，还是砍掉其他地方的预算？尽管部分企业在考虑踩下 AI 投资的刹车，但 **越来越多的公司选择向传统的 SaaS 产品开刀**。他们深刻地意识到，AI 能赋予他们指数级的增长速度，因此他们宁愿忍受短期的财务阵痛，也要坚定押注，因为他们确信：随着规模法则（Scaling Law）的不断演进，AI 的成本必定会呈指数级下降。

即便 AI 的普及率正在狂飙突进，但我今天完成与六个月前同样工作所付出的成本，实际上已经暴跌了。当然，我现在利用 AI 所能覆盖的业务边界，也远比当时广阔得多。面对这种范式转移，各家企业的应对策略大相径庭：有些公司甚至宁愿裁员，也不愿削减半点 AI 开支。**归根结底，在这场生产力的军备竞赛中，那些试图限制 AI 投入、勒紧算力裤腰带的企业，终将在创新能力和效率迭代上被时代的滚滚洪流碾压在尘埃里。**

主持人 Blake Hyman: 明白了。降低增量成本的方法之一，是选择更便宜、有时甚至没那么“聪明”的模型，而不是一味追求最前沿的模型。

正如我所说，我认为这些技术发展还处于非常早期的阶段，但我很好奇：像你们这样的公司，是否会在某个阶段认为，对于特定类型的工作，使用类似 DeepSeek V4 这样的模型才是最优解？

当然，对于需要更高智能的任务，你可能就需要依赖成本稍高一些的模型。这是否也是你们的考量之一？

迪伦·帕特尔: 我认为这对某些客户来说绝对是考量之一。你必须将 AI 的工作负载(Workloads)划分为两类。

第一类是 **将 AI 集成到现有的业务流程中**。比如，客户发给我一份文档，我根据特定标准进行检查，将其输入模型，模型处理完毕，任务就结束了。在这里，我只需要达到及格的质量线即可。一旦达标，我就可以不再追求提升模型性能，而是通过等待更新、更具性价比的模型来降低成本。

我们看到，AI 模型的性价比正以每年约 60 倍的速度飙升。当你达到某个质量标准后，仅仅过了一年，维持该标准的成本就会大幅骤降。DeepSeek 的问世之所以让人震动，是因为它比 GPT-4 便宜了整整 600 倍。考虑到 DeepSeek V3 大约是在 GPT-4 发布两年后推出的，再结合这个领域的复合式进化，我们正在见证成本的指数级暴跌。因此，**如果你有一个固定的工作流并接入了 AI，一旦达到了目标质量，你的核心策略就应完全转向极致的成本削减。**

第二类则是 **AI 辅助任务**，我认为大家在这里存在一些认知误区。如果我是在日常工作中利用模型来帮我查资料或解决问题，真正的成本优化，其实根本不是切换到更便宜的模型。

在这种场景下，**真正的成本优化，往往是通过使用最新、最强的模型来实现的**。举个例子，如果像 Claude 4.6 Opus 这样的上一代模型需要消耗 100,000 个 token（词元），还要经过多轮来回对话才能完成一项任务；那么新版模型 4.8 可能只需要一次交互、消耗 25,000 个 token 就能完美搞定。由于生成的 token 数量大减，加上节省了我不大量的时间，总成本反而是更低的。

当我观察开发者或知识工作者时，我发现降低成本的秘诀绝不是用“更便宜”的模型。而是把过去需要跟老模型“反复拉扯”的任务，交给最新、最强大的模型。这些新模型往往能一步到位地跑通整个 workflow，消耗的 token 远少于以往，这正是我们在早期 Opus 版本推出后所看到的现象。

在推出 Opus 4.7 版本时，我们的成本确实在第一周下降了，但随后又迅速飙升，因为大家使用模型的频率越来越高。为什么会飙升？因为人们适应了新的 workflow：手头原有的工作干完后，他们顺手就干了更多的工作。在从 4.7 过渡到 4.8 版本时，这种模式再次重演；成本下降了大约一周到一周半，然后随着用户意识到自己能完成更多工作，成本再次攀升。因此，**你必须把生产力和成本放在一起衡量。**

谈到 AI 助手，token 的使用效率至关重要。这也是为什么 Anthropic 的表现一直优于 OpenAI 的部分原因，因为他们的模型通常在 token 效率上更高。虽然 OpenAI 的模型往往能处理 Anthropic 模型搞不定的前沿科学、数学和编程任务中的边缘用例(Edge Cases)，但它们要花三倍的时间，消耗四倍的 token，这导致其成本极其高昂。

此外，模型效率越低，人与 AI 之间的反馈闭环就越慢。从客户体验的角度来看，吩咐模型去执行任务然后过会儿再来查看结果，和苦苦盯着一个耗时四小时的项目，两者有天壤之别。无论是单次长时间的运行调用，还是多轮的来回交互，得益于卓越的 token 效率，Anthropic 在这种“人在回路”(Human-in-the-loop)的场景下，往往表现得更好、更快。

这正是我们公司绝大多数业务依然坚持使用 Anthropic 的主因。虽说确实有人用 OpenAI 来处理特定任务——通常是那种丢给 Codex 等模型去彻夜运行的工作——但绝大多数日常任务依然由 Claude 包揽。这揭示了当前 AI 落地部署中最有趣的一个现象。

模型能力、token 效率和成本之间的关系很难一刀切地去拆解。但核心逻辑是：**对于某些任务，你的策略是锁定模型质量，然后坐等模型降价；而对于另一些任务，你反而必须追求最聪明的模型，因为“最聪明”往往意味着“最省钱”。**

主持人: Dylan，我想把话题稍微转向硬件，听听你的看法。我知道在今年早些时候你的一期 Newsletter（时事通讯）中——如果观众还没看出来的话，我是你这本通讯多年的死忠粉了——有一篇文章专门探讨了内存(Memory)。

内存市场历来都具备强周期性，通常是 18 到 24 个月的上行期，接着是 18 到 24 个月的下行期。我们知道，眼下几乎所有硬件都处于紧缺状态。只要你做的是数据中心相关的零部件，现在的问题根本不是你能否买到货，而是你到底要排队等多久。在当今这个世界，你似乎很难轻易买到任何零部件。

凭借你在硬件领域的深厚经验，你认为像内存这种过去一直被视为标准化大宗商品(Commoditized Product)的东西，接下来会发生怎样的突变？毕竟在过去的 40 年里，大家就是顺着上行周期赚钱，熬过下行周期，周而复始。

迪伦·帕特尔: 是的，我并不是说未来就不存在周期了。周期肯定还是会有。显然，我们眼下正处在一个超级周期(Super Cycle)里，上行的势头极其疯狂，未来也必定会迎来下行期，而且下行期也会相当惨烈。但显而易见的是，即使从前一个谷底到下一个谷底的跨度，整体的增长依然是巨大的，对吧？

所以我认为，现在去探讨内存和其他硬件，关键要看到整个产业形态正在发生的巨变。从历史上看，上行周期会让终端市场的规模增长 50%。因此，对于内存这类价格极具弹性的大宗商品市场，相关公司的股票往往会翻上 2 倍到 3 倍。但今天的情况截然不同；不仅不是仅仅增长 50%，在过去的短短几年里，总支出已经翻了一番，而且接下来还要再翻一番。

既然总支出翻倍了，当你去观察不同终端市场的价格弹性时，你会发现内存价格已经暴涨了 4 倍，并且在产能增长之外，价格还要再涨 2 到 3 倍。所以，相关股票在最终回落之前只会一路狂飙。我认为内存真正让人兴奋的地方，并不仅仅在于这是一个终端市场的现象——不仅仅是因为市场火爆、商品弹性大，或者因为内存是大宗商品，导致其价格与终端需求高度挂钩。

真正有趣的——这也是我们在 2024 年 o1 发布时写到的观点——是 OpenAI 推出的 o1 作为首个推理模型(Reasoning Model)，掀起了一场全新的推理模型热潮。OpenAI、

Anthropic、DeepSeek 以及许多其他公司都在大力挖掘这种潜力，让模型去执行长周期的智能体任务(Long-horizon Agent Tasks)。

当我们深入研究时发现，最有趣的是 o1 问世后，工作负载(Workload)发生了翻天覆地的变化。以前聊天时——当你跟 ChatGPT 对话时——你可能会发送一段 50 个字或 500 个字的提示词(Prompt)，然后它会给你回复。这个输入输出的比例，也就是上下文长度(Context Length)，大概只有几千。假设上下文长度是 2,000。这意味着当你在运行推理(Inference)时，每生成一个 token，你都需要将所有的权重(Weights)读取到芯片中。

你要把所有的上下文读取到芯片中，处理一个 token，然后再开启下一轮迭代。你要不断读取所有的 token、上下文以及权重，而存储上下文的地方就是所谓的 KV 缓存(KV Cache)。正是它在所有这些 token 之间建立了上下文关联。

有意思的地方在于，当你运行模型推理时，不管上下文长度是 1,000 还是 100,000，在权重方面，你依然必须读取所有的权重。因此，对于权重而言，推理过程的内存读写强度是固定不变的。然而在 KV 缓存这边，当你读入 1,000 个 token 和 100,000 个 token 时，两者的差异是极其巨大的，尽管它们所需的计算量其实差不多。由于 KV 缓存的内存管理机制，你在算力成本上或许能侥幸过关——你的计算成本不会暴增，但你的内存成本却会直冲云霄。

在 2024 年 12 月关于 o1 的深度分析中，我们明确指出，**预训练规模法则(Pre-training Scaling Law)正在让位于推理规模法则(Reasoning Scaling Law)**。o1 的出现代表了一次重大的阶跃式突变。我们探讨了 KV 缓存将如何因为推理需求而呈爆炸式增长，从而使内存成为这波浪潮中最大的赢家。在整个 2025 年，我们始终对内存行业无比兴奋。到了 2026 年 1 月，当大家纷纷猜测内存价格上涨 50% 是否已经触及周期大顶时，我们给出了相反的论断。我们坚信，在未来三年里，内存产能每年仅仅增长 20% 到 30%，但市场需求却在连年翻倍。

因此，内存价格必将继续狂飙。那些对价格敏感、承受能力较弱的内存消耗大户——比如智能手机和笔记本电脑厂商——最终会被高昂的成本逼迫着削减需求甚至出局。[这将硬生生地为 AI 的吞噬力让出一条血路](#)。由于产能增长远远不够，内存价格必须一直涨，涨到把其他需求挤出市场，直到达成新的供需平衡为止。归根结底，我们的核心观点是：[内存正步入一场将持续数年之久的长期缺货时代](#)。

纵观第一季度和现在的第二季度，我们看到存储(Memory)市场表现极为火爆，一路飙升。尽管偶尔会因为一些随机因素出现价格回调，但整体趋势始终是稳步上扬的。虽然这不是投资建议，但我们认为价格还会继续攀升，因为市场报价仍在不断上涨。

尽管一些主打中低端市场的中国智能手机制造商（如小米）表示其出货量下降了 40%，但我们尚未看到高端市场受到波及。

明年，iPhone 和 MacBook 的价格势必会上涨。目前，如果 MacBook 或 iPhone 涨价 100 美元，市场可能不会有太大的反应；然而，在人工智能(AI)的需求得到满足之前，存储价格将持续走高。这意味着智能手机的涨幅将远不止 100 美元，而是必须达到几百美元。到了某个临界点，当 AI 需求得到满足，移动设备和消费硬件市场被迫调整时，市场将会达到一个新的平衡。尽管如此，由于人们总是需要更换新的手机和笔记本电脑，而存储终端市场的产能增长速度又相对滞后，我们终将迎来一个新的供需平衡点。

当我们审视整个生态系统时，真正关键在于：[哪些零部件处于短缺状态，以及哪些公司具备定价弹性](#)。例如，台积电(TSMC)在定价上缺乏弹性，他们是公平可靠的合作伙伴，注重维系长期合作关系，通常只会提价 5% 到 10%。相比之下，存储公司身处大宗商品化市场(Commodity Market)，他们任由现货和合约市场来决定价格，这甚至会导致价格飙升两到三倍。总有一天，你会看到这些价格腰斩，因为存储芯片未必配得上 85% 的毛利率。虽然目前存储的毛利率还没达到 85% 或 90%，但正朝着这个方向狂奔，随后必然会迎来市场的价格回调。

我们在存储市场中看到了这种周期性震荡，而像台积电和阿斯麦(ASML)这样的公司则不会经历如此极端的定价波动。归根结底，[生态系统的不同环节会根据 AI 需求传导的深浅，产生不同程度的共振——在 AI 上每投入一美元，可能转化为某个产品的一分钱收益，却能化作另一个产品的五分钱利润](#)。

因此，基础设施供应链中的不同终端市场，从中获取的红利也大相径庭。除了需求水位之外，我们还必须考量市场动态：它是处于垄断还是寡头垄断？这是一个高度竞争的市场吗？它的价格是因长期协议而保持稳定，还是完全受制于供需关系的大宗商品市场？无论是存储芯片、多层陶瓷电容器(MLCC)、PCB 钻头还是铜箔，[真正决定其价格上涨的驱动力，是需求的实际传导效率以及底层的市场结构。这些才是真正主导基础设施供应链演变的底层逻辑](#)。

主持人：如果你采用这个框架，你会发现市场似乎年复一年地在觉醒，正如你所说，意识到所谓的“潜在短缺”。今年早些时候，OpenAI 和 Claude 在各大网站上现象级爆红，唤醒了人们对 AI 智能体(AI Agents)及其无限潜力的认知。借助你刚才描述的框架，我很想听听你对 CPU 市场的看法。在 AI 发展的头三年里，我几乎没听到过“CPU”这个词；但在今年，CPU 却成了高频词汇。

迪伦·帕特尔：在 CPU 方面，有趣的是，我们在去年 11 月为客户提供的一些机构研究报告中，就已经开始重点探讨这个问题了。当时 OpenAI 和 Anthropic 开始与亚马逊、谷歌、微软等巨头达成协议，买断或租空了他们服务器集群(Fleets)中所有的 CPU。从去年年底一直到今年，CPU 的需求迎来了重大的爆发拐点。

让我们来剖析一下背后的逻辑。最初，AI 的训练和推理（当时主要是短上下文）高度依赖于算力和网络。然而，[随着预训练\(Pre-training\)逐渐向强化学习\(Reinforcement Learning\)演进，以及传统的对话式推理转变为智能体工作流\(Agentic Workflows\)，我们看到 CPU 的需求迎来了重大的爆发拐点](#)。

预训练与强化学习的转变有着本质的区别：预训练是将整个互联网的数据集“填喂”给模型进行训练；而在强化学习中，模型需要生成合成数据(Synthetic Data)或做出推理选择，然后放入一个环境(Environment)中去校验。这个环境可能是在运行代码的单元测试(Unit Tests)，也可能是一个模拟了某个网站、工程系统或其他任何平台的沙盒(Sandbox)。

运行这些环境需要消耗大量的 CPU 算力。在发生这种范式转变之前，预训练期间对词元(Tokens)的实际处理并不太需要 CPU 算力。但现在，最吃性能的环节变成了环境校验：“我生成的这些词元有效吗？它们在 Python 或 C 编译器中能否跑通？如果我试图执行一笔电商交易，它们在网站环境里的运行状况如何？”作为智能体工作流的一部分，系统在幕后不断地进行这种高强度的测试，这就需要海量的 CPU 资源支撑。

另一方面则是实时推理(Live Inference)模式的转变。在传统的聊天模式下，交互非常简单：我提出问题，它给出答案，一轮交互就结束了。我顶多再追问几个后续问题，仅此而已。然而，现在我们探讨的是智能体工作流，模型在幕后不断进行工具调用(Tool Calls)。它会自发决定：“好的，我要去搜索引擎搜一下这个。”或者“我要去数据库里查一下那条数据。”又或者“我要去调用 Python 解释器。”它会自己写一段代码来检查刚才的输出，甚至完成代码编写、编译并部署的全流程。[这些智能体工作流由于必须与真实的外部世界发生物理级交互，最终导致对 CPU 算力的饥渴呈指数级上升](#)。

人类直接与模型交互是一回事：我下达指令，模型给我回复，我阅读后觉得“没问题”，然后手动复制粘贴到其他地方。但当模型自己去与互联网世界产生交互时，情况就截然不同了。在这个计算闭环中(In the Loop)会产生庞大得多的计算量——需要成倍的 CPU——来在系统内部反复抛接和校验答案。无论是强化学习还是智能体工作流，这两种新范式都需要极为庞大的 CPU 算力集群来支撑。

那么最终的商业演变是什么？既然我们需要海量的 CPU，我们就不妨重新评估一下目前的市场结构。过去市场上主要就是两大玩家：英特尔(Intel)和 AMD。现在 ARM 也下场发布了 CPU，作为极具竞争力的新入局者，这直接引爆了 ARM 的股价。此外，亚马逊(Amazon)虽然是该领域的领头羊，但微软(Microsoft)和谷歌(Google)也都在相继推出自研 CPU，甚至连英伟达(NVIDIA)也推出了自己的 CPU。直到两年前，这个市场几乎还是英特尔和 AMD 的双头垄断，而如今却已是群雄逐鹿。

亚马逊已经夺取了相当可观的市场份额，目前英伟达和 ARM 也开始攻城略地。那么终端市场的最终走向如何？由于需求呈爆炸式增长，英特尔和 AMD 实际上拥有了提价的底气。而亚马逊则能够从 CPU 中攫取令人咋舌的利润率，因为他们不只是“制造并出售”，而是“制造并出租”。他们的 Graviton CPU 正在被大规模租赁，带动了订单量的激

增。

英伟达过去只销售与自家 GPU 绑定的 CPU，但现在他们正凭借 Grace 架构单独出售 CPU。他们给出的 CPU 营收业绩指引(Guidance)高达 200 亿美元。尽管这在英伟达的整体营收中可能只占一小部分，但当你放眼英特尔、AMD、ARM，以及像亚马逊这样能够赚取基础设施即服务(IaaS)长尾收入（而不仅仅是一次性销售收入）的公司时，你会意识到，[在这个赛道深处，一场足以颠覆产业格局的巨变正在悄然发生。](#)

主持人Blake Hyman： Dylan，顺着刚才的话题，关于CPU，我听到的一些讨论是，至少现在有观点认为，用于AI智能体(Agent)的CPU与历史上传统的CPU在某些方面有所不同。也就是说，CPU核心是专门针对智能体活动(Agentic Activity)进行了优化的，这正是我记得黄仁勋在提到Vera CPU时所暗示的内容。

此外，关于GPU与CPU比例的讨论也非常多，这显然突显了市场对CPU的需求方向和需求量大。你能否针对这两个话题为我们提供更多细节？因为我认为……

这个概念在宏观层面大家都很容易理解，但在技术层面，可能有些细节被一笔带过甚至掩盖了。我不确定这仅仅是营销手段，还是确实存在这种技术上的必然性。

迪伦·帕特尔特： 在处理智能体工作流(Agentic Workflows)时，CPU的用途差异很大。例如，在某些工作流中，模型运行并输出所有词元(Token)后，将其发送给CPU工作流，等待CPU处理完任务，最后再接收返回的数据以继续后续工作。

核心问题在于，运行模型的算力资源在等待CPU时是否会发生停顿(Stall)。在某些情况下会停顿，而在其他情况下则不会。在模型算力发生停顿的场景下，CPU的架构设计需要截然不同。其基本原则在于：你是优先考虑核心数量，还是优先考虑核心速度？

CPU架构中有一个定律：如果你将CPU核心的尺寸增加一倍（意味着芯片上的核心数量减半），单个核心的性能并不会提升两倍，相反，单核性能可能只会提升约50%。虽然这涉及复杂的工程问题，且权衡取舍并不简单，但这仍然是我们思考该问题的一种有效方式。

所以，如果看英伟达为Vera设计的CPU……

它拥有不到100个核心，但这些核心比AMD的核心更快。AMD的旗舰CPU拥有256个核心。因此，两者在CPU核心数量上存在显著差异。英伟达的核心虽然更快，但并未达到AMD CPU核心的两倍速。因此，这其实是在设计空间上做出的权衡。

对于某些AI算力必须停顿以等待CPU处理的工作负载，CPU的总性能反而不如单核性能重要。如果我的核心数量减半，但速度快了50%，那么我等待CPU核心的时间就会大大减少。我并不一定需要超高并发的的工作负载(Parallel Workload)；[我真正需要的是此时此刻就把这个特定任务搞定。](#)在AI算力发生停顿的情况下，我需要尽可能快的核心，并愿意为了某些类型的智能体工作流牺牲多核性能。

而其他类型的智能体工作流运作方式则完全不同。想想那些团队是如何按API调用的方式使用Claude的，每年投入数百万美元。Claude处理着海量的词元(Token)，但它们服务的不是单一用户，而是将整个计算基础设施上数十万用户的需求进行批处理(Batching)。如果一个响应正在等待我这边的CPU去执行，那么底层的算力资源其实仍在为其他人服务。在这种场景下，如果CPU速度较慢但数量更多，它就能胜任不同类型的任务。

最后，我们必须区分AI的主动使用与AI生成内容的部署。如果我们观察全球范围内的代码提交(GitHub Commits)，其数量比去年增长了数倍——不仅是10%或50%的增长，而是几倍的跃升。这意味着全世界正在生成并部署大量的代码。其中许多代码，如网页爬虫、分析引擎或业务流程自动化工具，并不一定需要超高性能的CPU核心，它们在经济高效的CPU上也能运行得非常完美。

当你审视整个行业的产品图谱(Industry Continuum)时，英伟达打造了性能最高的CPU核心；然而，它并不一定能提供最大的总算力(Total Compute)——即CPU核心数乘以单核性能。实际上，在该特定指标上它们并不占优势。相比之下，AMD和亚马逊提供了显著更多的核心——多达数百个——但单核性能较低。ARM架构的芯片也属于这一阵营。所以问题变成了：你想处在这个产品图谱的哪个位置？对于某些工作负载，你需要英伟达的高性能核心；而对于其他工作负载，你则需要Graviton或AMD的CPU。这并不是简单的非此即彼。

至于CPU的需求比例，不可否认它正在增加。我们是在去年底的机构研究报告和1月通讯中首个指出这一趋势的。自那时以来，许多CPU相关股票大幅飙升。ARM、Intel和AMD的股价都显著上涨。然而，[卖方机构\(Sell-side\)往往缺乏对技术的深刻理解，他们开始编造市场叙事，暗示CPU与GPU（或AI算力）的比例正严重向CPU倾斜。这纯属无稽之谈。](#)

重申一遍，如果你看一套满配的Blackwell系统，单颗芯片成本高达50,000美元以上。如果CPU和GPU比例是1:1，那么CPU的成本仅为5,000美元左右。因此，如果市场销售了3,000亿到5,000亿美元的Blackwell芯片，你只会看到300亿到500亿美元的CPU销售额。这正是人们忽略的细节。虽然CPU市场在增长，但大部分资本支出(CapEx)仍流向了AI算力和内存。该市场此前被低估，现在的估值只是趋于合理。我们必须认识到，CPU需求的增长不会无限期地超过AI专用集成电路(ASIC)；相反，我们看到的只是市场的“价值重估与规模重塑(Right-sizing)”。

本质上，从2023年到2025年，各家公司售出了数百万颗AI芯片，但采购的CPU却少得可怜。现在，CPU需求迎来了拐点(Inflected)，因为企业正处于“补缺模式(Catch-up Mode)”。除了当前正在采购的算力外，他们还需要购买大量CPU，来为过去几年积攒的算力做配套平衡。一旦这一积压需求被消化，这种极端的暴涨势头就会减弱，我们将回归到渐进式的增量增长。

打个比方，如果你考虑1个CPU配2个GPU的比例，且每个GPU售价50,000美元，每个CPU售价5,000美元，那么每在GPU上花费100,000美元，在CPU上仅花费5,000美元。从长远来看，这并不足以支撑CPU市场的爆发式增长。虽然情况肯定比过去要好，但当前这种“荒谬”的旺盛需求，主要是因为过去三年出货了1,000万颗GPU和AI ASIC，而它们在部署时缺乏足够的CPU配套。我们目前正处于一个大规模的补缺阶段。一旦积压清空，市场将进入稳定状态。[我们只不过是处在CPU的一个迷你周期\(Mini-cycle\)中罢了。](#)

主持人Blake Hyman： 这些背景信息非常棒，真的非常有帮助。

转向网络领域，探讨一下技术栈(Stack)的另一环。我认为这也引起了许多投资者的关注，特别是在大家深入研究光通信供应链(Optics Supply Chain)及其产能瓶颈时。我们看到有预估称，共封装光学(Co-packaged Optics, CPO)虽然被频繁提及，但可能要到2027年或2028年左右才会真正落地部署。

当你思考“能用铜则用铜，必须用光才用光”(Using copper when you can and optics when you must)**这一理念时，行业显然正在发生转型。黄仁勋在台北电脑展(Computex)上对此进行了详细探讨，这也让Marvell等公司备受瞩目。

对于光器件，以及你如何看待未来两年数据中心在网络架构方面的演进，你还有什么独到的见解吗？

迪伦·帕特尔特： 显而易见：随着模型规模越来越大，我们该如何跨模块(Modules)运行它们？又该如何进行训练？在光学技术栈中存在许多不同的细分领域。电信光通信(Telecom Optics)领域由 Ciena 等公司领跑，周围环绕着众多配套的供应链。再看数据通信(Datacom)领域，特别是芯片到芯片的通信。该领域目前涵盖了铜缆和光学技术，且这两个领域都在蓬勃发展，因为网络设备(Networking Content)的增长速度已经超过了其他任何硬件类别。在与AI芯片相关的支出中，网络设备的占比正从不足10%攀升至10%以上；而当进入共封装光学(Co-Packaged Optics, CPO)时代，这一占比还将进一步飙升至20%到30%。

因此，我们迎来了网络硬件需求的巨大增长。但另一方面，CPO 对整个行业而言是一次重大的“阶跃式变革”(Step-function Change)，我认为市场对此有些过于狂热了。尽管大家都认可 CPO 的重要性，但目前其实处于一个相对平静的蛰伏期。在我看来，CPO 不会在2027年到来；现实情况是，它要到2028年末才会出现，而2029年才是共封装光学真正实现规模化量产的元年。

目前的挑战比比皆是，主要集中在制造环节。如果今天能以理想的成本部署CPO，所有人都会趋之若鹜，但这极其困难。目前的制造规模远未达标，良率堪忧，且芯片本身也尚未针对CPO进行专门设计。这是一项极其复杂、极难爬坡扩产的工艺。因此，大家会尽可能久地坚持使用铜缆。例如，Blackwell架构完全采用铜缆，而Feynman（继Rubin和Rubin Ultra之后的下一代 NVIDIA GPU 架构）也将继续依赖铜缆。目前我们甚至还不到Rubin出货的阶段，所以在GPU上真正看到共封装光学之前，还需要经历几代芯片的更迭。

交换机侧的共封装光学确实比 GPU 或 AI ASIC 侧来得更早。但即使如此，随着集群规模的不断扩大，每个GPU需要配置更多的光学器件，或是更多的有源电缆(Active Electrical Cables)及类似解决方案。这引发了行业动态的重大转变。周一，我们在 SemiAnalysis 为机构研究订阅客户发布了一份关于该时间节点的简报。虽然我们的长期共识依然是——CPO是大势所趋，并最终将取代铜缆，但在中期内，我们实际上非常看好铜缆和非CPO光学技术。

由于我们观察到下游出现了特定的延迟（例如Feynman架构未能全面采用CPO），我们目前对CPO持一定程度的看空态度。正因如此，像安费诺(Amphenol)这样主营背板连接器和电缆的铜缆核心厂商，在未来几年的市场表现实际上会远远超出此前的预期。我们曾以为CPO会更早放量，但它已被推迟。这种转变在供应链中司空见惯，但技术转型的大势仍在滚滚向前。

如果你今天闭上双眼，五年后再次睁开，你会发现光学领域的版图已经发生了翻天覆地的扩张。这其中巨大的潜力很大一部分已经反映在股价中，但仍有未被完全消化的空间，其中必然存在一些需要考量的局部错位(Local Disjunctions)。我们一直在推进的研究（包括与你们的合作）的一个核心目的，就是找准这些因素的权重。具体而言，我们需要精准评估共封装光学(CPO)与非CPO方案之间的平衡，以及传统光收发器与铜缆之间的持续博弈。

实际上，铜缆技术还有很长的路要走，许多正在涌现的创新技术延缓了市场对CPO的迫切需求。最核心的灵魂拷问依然是：为什么要优先选择CPO？归根结底，光电集成的成本远高于纯电信号传输。然而，电信号传输的阿喀琉斯之踵在于：如果没有中继器或光学器件的加持，它根本走不远。

因此，在技术演进的连续体中，始终存在着不断的权衡与取舍。虽然CPO的全面到来是历史必然，但目前的趋势表明，它的大规模普及比预期还要再晚一些。

主持人： Dylan，在我们进入最后一个压轴话题之际，前面我们已经探讨了模型、GPU、CPU、内存和网络。如果我们对所有数据中心里那只“房间里的大象”（显而易见的核心问题）避而不谈，那就太失职了：那就是如何获取电力，以及如何将电力转换为可用的形式。

我知道你在时事通讯中写过关于直流电与交流电的对比，以及其他的细节。当我们看到超大规模云厂商(Hyperscalers)正豪掷千金建设这些数据中心——甚至直接在数据中心现场建设“电表后”(Behind the meter)发电厂时，我们该如何看待这种激增的电力需求，以及电网供电与非电网供电之间的平衡？

我知道这是一个宏大的话题，但我认为我们今天必须得聊聊这个。

迪伦·帕特尔： 是的，数据中心的扩张规模是惊人的。今年，我们部署了20吉瓦(Gigawatts)的数据中心。明年，这个数字将飙升50%达到30吉瓦，再下一年更是会达到每年50吉瓦。数据中心容量的增长堪称狂飙突进。

人们正面临着许多棘手的局部挑战。能源是最大的拦路虎，其次是政治因素和施工限制。建设数据中心、跑通许可和审批流程举步维艰，在政治层面上，也常有反对声音试图阻挠。但归根结底，真正扼住这种增长咽喉的，依然是能源供应。

能源系统可以拆解为三个环节：发电(Generation)、输电(Transmission)和转换(Conversion)。发电是产生电子的源头；输电是将电力运送到数据中心的通道；而转换之所以不可或缺，是因为电网传输的电力规格根本无法直接供芯片使用。芯片需要截然不同的电压规格，因此电力转换链路至关重要。

在这三个环节中都蕴藏着看涨的机会，但“输电”环节最难让人感到乐观。这主要是由于监管障碍、扩建产能的政治阻力，以及地方公用事业垄断的运作机制——新建一条输电线路需要将成本平摊给电网上的所有用户，而不能仅由单一用户承担。这种机制上的错位，使得扩充电网容量变得步履维艰。

然而，在发电和转换领域，我们看到了极具潜力的发展。在发电侧，我们正在经历一场向“数据中心现场发电”的巨大范式转变。**我们预测，几年之内，数据中心一半的新增电力将来自“电表后”(Behind-the-meter)的现场发电。**我们内部有一个模型——由曾参与建设哈萨克斯坦发电厂的团队成员 Ellie 负责管理——该模型追踪了每一个发电、输电和负载资产，数据确凿地证明：“电表后”发电的增长正在呈井喷之势。

尽管在许可和合规方面常有博弈（比如对废气排放许可或天然气管道建设的抗议，正如某些甲骨文(Oracle)数据中心所遭遇的那样），但最终的结果是，“电表后”发电正迎来前所未有的繁荣。这在很大程度上依赖于天然气，包括 GE Vernova、三菱(Mitsubishi)或西门子(Siemens)等公司生产的双联合循环燃气轮机。

除此之外，能源领域的创新正如百花齐放，涵盖了往复式发动机(Reciprocating Engines)、工业燃气轮机以及各类柴油发动机。人们甚至开始将火车、轮船和卡车的发动机“爆改”后用于数据中心发电。美国具备雄厚的工业基础来支撑这一点，每年能生产数以百万计的往复式发动机。将这些发动机改造为燃烧天然气（而非柴油）相对简单，当然，直接使用柴油依然是一个可行的选项。

你只需要在发动机上接入一个电机并对其进行反向驱动(Back-driving)，就能源源不断地产生电力。你可以大规模地复制这种模式来发电。我们将看到超过10吉瓦的数据中心采用这种技术来建设：拿来柴油卡车发动机，在出厂时轻松将其改装为天然气驱动，反向驱动电机，然后直接安装在数据中心现场。想象一下，一个数据中心背后由数百台这样的设备支撑，你只需要雇佣一批汽修厂的熟练工，全天候维护这些柴油机即可。只要保留一定的冗余缓冲，当某些机组停机检修时，整个系统依然能满功率运转。显然，你需要在中间配置电池系统进行稳压，因为你绝不想让数据中心的负载波动去冲击发电机组。这催生了一条完整的“电表后”供应链，这是一个令人无比兴奋的新蓝海。

此外，大约在两年内，“光伏+储能”的综合成本将低于天然气发电。诚然，“光伏+储能”的供应链较为复杂，且取决于你对可靠性级别的要求。如果你只需要熬过一个晚上的电池电量，成本很低；但万一连下两天雨，你需要能支撑三天的电池储备呢？这完全取决于你需要多少个“9”（如99.999%）的可靠性。然而，得益于中国卓越的制造能力和产业补贴，“光伏+储能”的成本正以极其惊人的速度下降。在未来的某个临界点，直接采用“光伏+电池”将成为最具性价比的选择。

再把目光放长远，还有太空数据中心——在那里你甚至不需要电池；只需把设备送入太空，展开太阳能电池板，一切就搞定了。从爆改柴油发动机、使用双联合循环燃气轮机，一路延伸到将芯片送上太空，发电方式构成了一个无限延展的连续体。这里面大有可为，蕴藏着无尽的财富机遇和激动人心的行业变局。

这正是为什么 SemiAnalysis 最大的垂直研究领域(Research Vertical)——你可能会认为是半导体——实际上却是数据中心、工业和能源。我们在内部将其称为 DEI 团队（这算是一个内部双关语），这个名字是由负责该团队的 Jeremy 想出来的。它是我们最重要的研究方向，因为我们在密切追踪每一个数据中心和每一座发电厂的动向。当我们识别出项目延期、新建项目，或者预测一家公司单季度将上线多少数据中心时，这是业内其他人根本无法做到的。整个行业对此都高度关注：谷歌想知道 Meta 在部署什么，Meta 想知道 OpenAI 在部署什么，所有人都在紧盯供应链的产能。

这是一个极度分散(Decentralized)的市场。在内存(Memory)领域，主要玩家只有三家；在加速器或半导体制造设备领域，也就屈指可数的几个名字。但在数据中心领域，供应链中不仅有数百家制造各种不起眼小零件的公司，有几十家建设数据中心的企业，还有几十家充当独立发电商(Independent Power Producers)或提供电池服务的公司。这是

一个极其复杂、充满动态变化的供应链，随时都在涌现新的创新。虽然数据中心目前仍是某种瓶颈，但这种制约不会永远存在——一切仅仅取决于你愿意多“疯狂”地去打破常规。

比如，拿卡车发动机进行改装，雇上一堆机械师来运营一个数据站点。这肯定不是最优解。很多人会说：“哦，这太离谱了。这有多可靠？做起来肯定非常折腾。”但确实有人在这么做，而且这行得通。尽管过程极其痛苦，但它确实管用。

再比如，“我要把它发射到太空去”。这也会非常折腾，让它运转起来极为困难，但它确实可行。因此，针对数据中心的问题，你总能找到解决方案，无论是采用高污染的原始发电方式，还是完全将其搬入太空。然而，在供应链的其他环节，你可能就没有这种灵活性。我认为，这正是该市场如此充满活力的原因：你会看到参与者在其中经历剧烈的跌宕起伏。

至于另一个部分——前面谈论的都是发电和输电端——接下来要看的就是转换端。你如何将电力从产生或传输的地方，转化为芯片所需要的电能？这背后有一条完整的供应链，无论是绝缘栅双极型晶体管(IGBT)、碳化硅(Silicon Carbide)、各种金属氧化物半导体场效应晶体管(MOSFETs)，还是氮化镓(Gallium Nitride) MOSFET。当我们从 12 伏升至 54 伏，再跨越到 800 伏直流电(DC)时，对应的转换供应链会发生怎样的变化？当固态变压器(Solid-State Transformers)迎来技术革新时，又会发生什么？

所有这些变化都在这个领域内上演。不间断电源(UPS)、备用电池、超级电容器(Supercapacitors)以及其他各种平滑电力的手段会如何演进？你如何将左侧产生的高碳、不稳定的电力，转换成右侧波动的负载所需的那种极致纯净的电力？你如何匹配它们？整条电能转换管线(Conversion Pipeline)真的让人非常非常兴奋。

就在上周，我们刚发布了一篇关于 800 伏电压的博客。最近，我们还在向机构订阅者探讨英伟达(NVIDIA) 在 Blackwell 架构上遇到的一些延迟情况。Rubin、Ultra、Blackwell 不再使用 800 伏电压了，这对供应链意味着什么？这意味着相关进度被推迟了一些。

主持人： Dylan，我代表我们团队向你表示衷心的感谢。如果以章节来看，这是你第一次参加我们的播客，但绝对不会是最后一次，因为还有海量的信息值得探讨。正如你多次直言不讳地指出，在整个技术栈中，一切都在时刻发生变化。要时刻跟上这些变化简直难如登天，对于普通人来说更是如此。

迪伦·帕特尔： 我想补充的另一点是，这条供应链真的太疯狂了。很多时候我们只关注那些大头，对吧？内存、CPU 和数据中心。但实际上，当你深入剖析供应链时，会发现那些局部的微小颠簸数不胜数。过去几个月里，我们一直在讨论印制电路板(PCB)钻头——就是在 PCB 上打孔的微型钻头，或者是上面覆盖的各种不起眼的铜箔。供应链中充斥着这些不起眼的小玩意儿，而它们同样经历着各种错位和中断(Dislocations)。

此外，存在于这些垂直领域的公司遍布世界各地。它们可能在台湾、日本、韩国或世界的其他任何地方进行交易。这就导致投资者并不总是能轻易地接触到这些公司。

我认为，这正是我们的合作模式真正令人兴奋的地方：我们能够对行业产生实质性的影响。我们能深入探讨这些供应链的动荡，并结合我之前提出的框架，全面覆盖我们想要研究的商业版图。我很期待能多来节目做客，并继续推进我们的其他合作。

主持人： 绝对欢迎。最后，为了满足合规团队的要求我必须在此声明：本播客中表达的观点和意见并不一定代表 WisdomTree 的立场，且可能随时发生变化。本播客呈现的任何内容均不应被视为预测、研究、投资或税务建议。所表达的信息和观点不构成买卖任何证券的推荐、要约或招揽，听众应完全自行决定是否依赖这些信息。请记住，过往业绩不代表未来结果。感谢大家今天抽出时间收听，我们期待未来再次相聚。保重。

参考资料: <https://www.youtube.com/watch?v=IHnxU9f-rwc>，公开发表于2026年07月09日

关注公众号后设标，掌握第一手AI新动态

btw：如果您对AI一线动态、AI产品构建及转型感兴趣，并愿意和小伙伴們分享互动，欢迎加入瓜哥交流学习群参与讨论（联系瓜哥wx：southmelon，注明：所在行业、申请入群原因），群内定期分享瓜哥手搓Agent整理的全球AI动态内参～

访问ima瓜哥AI知识库，一键查询AI业界大佬观点：点击瓜哥公众号头像->“服务”菜单->知识库。加入后在腾讯ima.copilot APP可随时@查询。

修改于